



湘潭大學

XIANGTAN UNIVERSITY

湘潭大学研究生课程实践论文

课程名称 机器学习

论文题目 神经网络的谱偏差及其在

Helmholtz 方程求解中的影响

所在学院 数学与计算科学学院

专业班级 数学 2 班

姓 名 孙贺龙

学 号 202521511212

2026 年 6 月 8 日

摘要

神经网络方法近年来被广泛用于偏微分方程的数值求解, 其中物理信息神经网络 (Physics-Informed Neural Networks, PINN) 通过把微分方程残差与边界条件写入损失函数, 为无网格求解 PDE 提供了一种灵活框架。然而, 神经网络的表达能力并不等同于训练过程的有效可达性。已有研究表明, 标准多层感知机在梯度型训练中通常具有明显的谱偏差: 低频成分较早被拟合, 而高频成分收敛较慢。Helmholtz 方程是典型的振荡型方程, 高波数情形下解的主频率与波数 k 同阶, 因此普通 MLP 或强形式 PINN 在求解时会面临训练困难、相位误差、采样不足与残差尺度放大等问题。本文从 Fourier 分解、线性化训练动力学和 Helmholtz 算子符号三个角度分析谱偏差的数学机制, 建立误差频率与残差放大的关系, 并通过一维函数拟合和一维 Helmholtz-PINN 实验展示低频目标与高频目标之间的训练差异。实验表明: 普通 MLP 对低频函数拟合较快, 而对高频函数误差下降明显变慢; 在 Helmholtz-PINN 中, 波数增大时相对误差和残差显著恶化。Fourier features 能改善高频函数的表示能力, 但强形式 PINN 仍受到优化、采样和残差尺度的制约。本文最后讨论了波数相关特征、损失归一化、自适应采样和弱形式 PINN 等改进方向。

关键词: 神经网络; 谱偏差; 频率原则; Helmholtz 方程; PINN; Fourier features

目录

1	引言	1
2	神经网络函数逼近与谱偏差	2
2.1	多层感知机作为参数化函数族	2
2.2	Fourier 视角下的误差分解	3
2.3	线性化训练动力学解释	3
2.4	Fourier features 的基本思想	4
3	PINN 的误差来源与数学结构	5
3.1	强形式残差与经验积分	5
3.2	强形式与弱形式的比较	5
4	Helmholtz 方程的振荡结构与频域符号	6
4.1	一维模型问题与非共振条件	6
4.2	Helmholtz 算子的 Fourier 符号	7
4.3	变分形式与非强制性	8
5	谱偏差对 Helmholtz-PINN 的影响	8
5.1	强形式残差中的敏感抵消	8
5.2	采样分辨率与波长	9
5.3	损失尺度随波数放大	9
6	数值实验	10
6.1	实验一: 函数拟合中的谱偏差	10
6.2	实验二: 一维 Helmholtz 方程的 PINN 求解	12
6.3	实验结果的数学解释	14
7	改进方向讨论	15
7.1	引入与波数相关的 Fourier 特征	15
7.2	弱形式与变分型 PINN	15
7.3	与传统 Helmholtz 求解器和神经算子的关系	15
7.4	采样策略与损失尺度	16
8	结论	16

1 引言

深度神经网络在机器学习中具有强大的函数表示能力。与传统数值方法相比,神经网络求解偏微分方程 (partial differential equations, PDEs) 的一个突出特点是: 它不必先构造固定网格上的离散函数空间, 而是直接用带参数的函数族表示未知解。设 PDE 的未知解为 u , 神经网络方法通常构造

$$u(x) \approx u_\theta(x), \quad (1)$$

其中 θ 表示网络权重和偏置。训练过程就是通过最小化损失函数确定 θ 。若损失函数中包含 PDE 残差、边界条件残差和可能的观测数据残差, 就得到物理信息神经网络 (Physics-Informed Neural Networks, PINN) 的基本框架 [15]。

PINN 的形式非常自然; 它也可以看作 Deep Galerkin Method 等无网格 PDE 学习方法的一种代表性实现 [16, 12, 8]。考虑边值问题

$$\mathcal{L}u = f \quad \text{in } \Omega, \quad \mathcal{B}u = g \quad \text{on } \partial\Omega, \quad (2)$$

其中 $\mathcal{L}$ 是微分算子, $\mathcal{B}$ 是边界算子。令 u_θ 为神经网络近似解, PINN 通常最小化如下经验损失:

$$\begin{aligned} \mathcal{J}(\theta) &= \mathcal{J}_r(\theta) + \lambda \mathcal{J}_b(\theta), \\ \mathcal{J}_r(\theta) &= \frac{1}{N_r} \sum_{i=1}^{N_r} |\mathcal{L}u_\theta(x_i) - f(x_i)|^2, \\ \mathcal{J}_b(\theta) &= \frac{1}{N_b} \sum_{j=1}^{N_b} |\mathcal{B}u_\theta(y_j) - g(y_j)|^2. \end{aligned} \quad (3)$$

这里 x_i 是区域内部采样点, y_j 是边界采样点, λ 是用于平衡边界项与内部残差项的权重。由于自动微分可以计算 u_θ 的导数, PINN 在形式上可以处理多种微分方程和边界条件。

不过, 神经网络的“可表达”与“可训练”是两个不同问题。万能逼近定理说明, 在一定条件下, 神经网络可以逼近广泛的连续函数 [2, 5]; 但这并不说明实际优化过程一定可以高效地找到相应参数。Rahaman 等 [14] 和 Xu 等 [20] 从 Fourier 角度指出, 标准深度网络训练中常表现出低频优先的现象, 即网络倾向于先拟合目标函数的低频成分, 再逐渐拟合高频成分。这种现象通常被称为谱偏差 (spectral bias) 或频率原则 (frequency principle)。

谱偏差对 Helmholtz 方程尤其重要。Helmholtz 方程的一般形式为

$$-\Delta u - k^2 u = f, \quad (4)$$

其中 $k > 0$ 是波数。该方程描述固定频率下的波动问题, 其解通常具有明显振荡性。当 k 增大时, 波长缩短, 解在同一区域内振荡次数增加。对于传统有限元方法, 高波数 Helmholtz 问题会带来网格分辨率要求、相位误差和污染效应等困难 [6, 1, 13, 3]。对于

PINN, 除这些波动问题本身的困难外, 还叠加了神经网络低频优先训练的谱偏差。因此, 研究谱偏差对 Helmholtz 方程求解的影响, 不仅有助于理解 PINN 的局限, 也有助于认识机器学习方法在科学计算中的适用边界。

本文围绕以下问题展开:

- (1) 神经网络训练中的低频优先现象如何用 Fourier 分解和训练动力学表达?
- (2) Helmholtz 算子的频率符号如何放大相位误差和频率误差?
- (3) Fourier features 为什么能缓解高频函数拟合, 却不一定完全解决强形式 PINN 的困难?

全文结构如下: 第 2 节介绍神经网络函数逼近与谱偏差; 第 3 节给出 PINN 的误差来源; 第 4 节分析 Helmholtz 方程的振荡结构与频域符号; 第 5 节讨论谱偏差对 Helmholtz-PINN 的具体影响; 第 6 节给出可复现实验; 第 7 节讨论可能改进; 第 8 节总结全文。

2 神经网络函数逼近与谱偏差

2.1 多层感知机作为参数化函数族

考虑标准前馈神经网络。给定输入 $x \in \mathbb{R}^d$, 一个 L 层多层感知机 (multi-layer perceptron, MLP) 可以写为

$$\begin{aligned} h_0(x) &= x, \\ h_\ell(x) &= \sigma(W_\ell h_{\ell-1}(x) + b_\ell), \quad \ell = 1, \dots, L-1, \\ u_\theta(x) &= W_L h_{L-1}(x) + b_L. \end{aligned} \tag{5}$$

其中 W_ℓ, b_ℓ 为可训练参数, σ 是非线性激活函数, 例如 $\tanh$ 或 ReLU 。监督训练通常最小化经验风险

$$\min_{\theta} \frac{1}{N} \sum_{i=1}^N |u_\theta(x_i) - f(x_i)|^2. \tag{6}$$

从函数逼近角度看, 网络 u_θ 给出了一个非线性参数化函数族。它与多项式、三角函数、有限元基函数等传统近似空间不同: 网络参数并不是线性系数, 优化问题通常也是非凸的。

虽然深度网络表达能力很强, 但训练过程受到优化算法、初始化、激活函数光滑性和损失函数结构的影响。特别是, 当目标函数具有复杂的高频结构时, 即使网络宽度和深度足够, 优化过程也未必能快速学习这些高频成分。

2.2 Fourier 视角下的误差分解

为清楚表达“频率”概念, 先考虑周期区间 $[0, 2\pi]$ 上的函数。若

$$f(x) = \sum_{m \in \mathbb{Z}} \hat{f}_m e^{imx}, \quad \hat{f}_m = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-imx} dx, \quad (7)$$

则 Parseval 恒等式给出

$$\|f\|_{L^2(0,2\pi)}^2 = 2\pi \sum_{m \in \mathbb{Z}} |\hat{f}_m|^2. \quad (8)$$

令 $e_\theta = u_\theta - f$, 其频率误差为

$$\hat{e}_m(\theta) = \hat{u}_{\theta m} - \hat{f}_m. \quad (9)$$

于是总的 L^2 误差可分解为不同频率误差之和:

$$\|u_\theta - f\|_{L^2}^2 = 2\pi \sum_{m \in \mathbb{Z}} |\hat{e}_m(\theta)|^2. \quad (10)$$

定义 1 (谱偏差). 若在梯度型训练过程中, 低频系数 $|\hat{e}_m(t)|$ 通常比高频系数更快衰减, 即对较小 $|m|$ 的模式有更快的误差下降, 而对较大 $|m|$ 的模式误差下降较慢, 则称该训练过程具有谱偏差或低频优先现象。

例如, 考虑

$$f_1(x) = \sin(5x), \quad f_2(x) = \sin(40x), \quad x \in [0, 1]. \quad (11)$$

两个函数的解析表达式都很简单, 但 f_2 在区间上的振荡次数明显更多。普通 MLP 在相同训练预算下通常更容易拟合 f_1 , 而对 f_2 的误差下降较慢。这说明神经网络训练难度不仅取决于函数公式是否简单, 也取决于目标函数的频率结构。

2.3 线性化训练动力学解释

谱偏差还可以从线性化训练动力学理解。考虑平方损失

$$\mathcal{J}(\theta) = \frac{1}{2} \int_{\Omega} |u_\theta(x) - f(x)|^2 dx. \quad (12)$$

这一视角与 NTK 理论有关, Jacot 等证明了无限宽极限下网络训练可由核梯度流描述 [7]。若在初始化 θ_0 附近线性化网络:

$$u_\theta(x) \approx u_{\theta_0}(x) + \nabla_{\theta} u_{\theta_0}(x) \cdot (\theta - \theta_0), \quad (13)$$

则梯度流近似满足

$$\partial_t u_t(x) = - \int_{\Omega} K_{\theta_0}(x, y) (u_t(y) - f(y)) dy, \quad (14)$$

其中

$$K_{\theta_0}(x, y) = \nabla_{\theta} u_{\theta_0}(x) \cdot \nabla_{\theta} u_{\theta_0}(y) \quad (15)$$

是神经切线核 (neural tangent kernel, NTK)。若积分算子 K 有特征分解

$$K\phi_j = \lambda_j\phi_j, \quad (16)$$

并将误差写为

$$e_t(x) = u_t(x) - f(x) = \sum_j c_j(t)\phi_j(x), \quad (17)$$

则由式(14)得到

$$\frac{d}{dt}c_j(t) = -\lambda_j c_j(t), \quad c_j(t) = c_j(0)e^{-\lambda_j t}. \quad (18)$$

因此, 误差模式的收敛速度由特征值 λ_j 决定。若高频模式对应较小的 λ_j , 则高频误差衰减慢, 表现为低频优先。这一推导不是对所有网络的完整证明, 但它给出了谱偏差的一个清晰数学图像: 训练不是均匀地压低所有频率, 而是由网络结构和优化动力学决定不同模式的衰减速度。

2.4 Fourier features 的基本思想

为了缓解普通 MLP 对高频函数学习困难的问题, Tancik 等 [18] 提出并系统研究了 Fourier feature mapping。其核心思想是先把低维坐标 x 映射为含有三角函数的高维特征:

$$\gamma(x) = (\sin(Bx), \cos(Bx)), \quad (19)$$

再用 MLP 学习

$$u_{\theta}(x) = N_{\theta}(\gamma(x)). \quad (20)$$

若一维情形下选择频率集合 $\{\omega_j\}_{j=1}^M$, 则可以写成

$$\gamma(x) = (\sin(\omega_1 x), \cos(\omega_1 x), \dots, \sin(\omega_M x), \cos(\omega_M x)). \quad (21)$$

Fourier features 的意义在于: 高频振荡不再完全由网络隐层从原始坐标中“慢慢学出”。与此相关, 使用周期激活函数的 SIREN 也被用于表示高频信号及其导数 [17]。因此, 高频信息可以通过输入特征或网络结构被显式编码。 , 而是在输入层就被显式提供。对于含有已知波数 k 的 Helmholtz 方程, 这一思想尤其自然, 因为解的主要振荡频率往往与 k 相关。

3 PINN 的误差来源与数学结构

3.1 强形式残差与经验积分

设精确解满足式(2)。PINN 的理想连续损失可写为

$$\mathcal{J}_{\text{cont}}(\theta) = \|\mathcal{L}u_\theta - f\|_{L^2(\Omega)}^2 + \lambda \|\mathcal{B}u_\theta - g\|_{L^2(\partial\Omega)}^2. \quad (22)$$

实际训练中使用采样点近似积分:

$$\mathcal{J}_N(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} |\mathcal{L}u_\theta(x_i) - f(x_i)|^2 + \lambda \frac{1}{N_b} \sum_{j=1}^{N_b} |\mathcal{B}u_\theta(y_j) - g(y_j)|^2. \quad (23)$$

PINN 的训练还会受到复合损失项梯度尺度不平衡的影响, 这一点在 Wang 等关于 PINN 梯度病态的研究中有系统讨论 [19]。因此误差来源至少包括三类:

$$E_{\text{total}} \approx E_{\text{app}} + E_{\text{opt}} + E_{\text{sample}}. \quad (24)$$

更具体地, 若 Θ 是网络参数集合, 则可以形式地写成

$$\underbrace{\|u - u_{\theta_T}\|}_{\text{total}} \leq \underbrace{\inf_{\theta \in \Theta} \|u - u_\theta\|}_{\text{approximation}} + \underbrace{\|u_{\theta_*} - u_{\theta_T}\|}_{\text{optimization}} + \underbrace{|\mathcal{J}_{\text{cont}}(\theta) - \mathcal{J}_N(\theta)|}_{\text{sampling}}, \quad (25)$$

其中 θ_T 表示训练 T 步后的参数, θ_* 表示理想损失下的最优参数。式(25)不是严格定理, 而是用于说明 PINN 与传统离散方法的差异: 即使表达空间足够大, 优化和采样仍可能成为主要瓶颈。

3.2 强形式与弱形式的比较

有限元方法通常先构造有限维空间 V_h , 再寻找 $u_h \in V_h$ 使得

$$a(u_h, v_h) = F(v_h), \quad \forall v_h \in V_h. \quad (26)$$

这里的弱形式、测试函数和试探函数空间都具有明确的变分意义。以一维 Poisson 方程为例:

$$-u'' = f, \quad u(0) = u(1) = 0. \quad (27)$$

乘以测试函数 $v \in H_0^1(0, 1)$ 并分部积分, 有

$$\int_0^1 u'(x)v'(x) dx = \int_0^1 f(x)v(x) dx. \quad (28)$$

相比之下, 强形式 PINN 直接最小化

$$\int_0^1 | -u''_\theta(x) - f(x) |^2 dx, \quad (29)$$

这要求网络二阶导数足够准确。对于 Helmholtz 方程, 这个问题更加明显, 因为强形式残差包含二阶导数项和 $k^2 u$ 项之间的精确抵消。

4 Helmholtz 方程的振荡结构与频域符号

4.1 一维模型问题与非共振条件

为突出主要机制, 本文考虑一维 Helmholtz 方程:

$$-u''(x) - k^2 u(x) = f(x), \quad x \in (0, 1). \quad (30)$$

齐次方程

$$-u'' - k^2 u = 0 \quad (31)$$

的通解为

$$u(x) = A \cos(kx) + B \sin(kx). \quad (32)$$

因此, k 直接决定了解的振荡频率。 k 越大, 波长

$$\lambda_{\text{wave}} = \frac{2\pi}{k} \quad (33)$$

越短, 单位区间内振荡次数越多。

考虑 Dirichlet 边界条件 $u(0) = u(1) = 0$ 。若 $k = n\pi$, 则 $\sin(kx) = \sin(n\pi x)$ 是非零齐次解, 问题不唯一。因此 Dirichlet Helmholtz 问题的非共振条件是

$$k \notin \pi\mathbb{N}. \quad (34)$$

本文实验选择 $k = 5, 10, 20, 40$, 这些数值均不等于 $n\pi$, 从而避免特征值导致的非唯一性。

实验中使用制造解

$$u(x) = \sin(kx), \quad (35)$$

并取 $f(x) = 0$, 因为

$$-u''(x) - k^2 u(x) = k^2 \sin(kx) - k^2 \sin(kx) = 0. \quad (36)$$

边界条件取

$$u(0) = 0, \quad u(1) = \sin k. \quad (37)$$

4.2 Helmholtz 算子的 Fourier 符号

在全空间或周期区间中, 考虑 Fourier 模式

$$\phi_\xi(x) = e^{i\xi x}. \quad (38)$$

一维 Helmholtz 算子

$$\mathcal{L}_k = -\frac{d^2}{dx^2} - k^2 \quad (39)$$

作用在 ϕ_ξ 上得到

$$\mathcal{L}_k \phi_\xi = (\xi^2 - k^2) \phi_\xi. \quad (40)$$

因此 Helmholtz 算子的 Fourier 符号为

$$p_k(\xi) = \xi^2 - k^2. \quad (41)$$

这说明 Helmholtz 方程的特征频率位于 $|\xi| = k$ 附近。若网络主要学习到低频 $|\xi| \ll k$, 则

$$|p_k(\xi)| = |\xi^2 - k^2| \approx k^2, \quad (42)$$

残差不会小。只有当网络近似中包含接近 $\xi = \pm k$ 的振荡模式时, 才可能有效降低残差。

命题 1 (单频误差的残差放大). 设误差 $e(x) = A \sin(qx)$ 。则 Helmholtz 残差误差为

$$\mathcal{L}_k e = (q^2 - k^2) A \sin(qx). \quad (43)$$

因此

$$\|\mathcal{L}_k e\|_{L^2(0,1)} = |q^2 - k^2| \|e\|_{L^2(0,1)}. \quad (44)$$

特别地, 若 $q = k + \delta$, 则

$$q^2 - k^2 = 2k\delta + \delta^2. \quad (45)$$

当 k 较大时, 即使频率偏差 δ 很小, 残差也可能被 $2k\delta$ 放大。

命题1揭示了 Helmholtz-PINN 的核心困难: 强形式残差不只要求函数值接近, 还要求网络学到正确的振荡频率和相位。若网络由于谱偏差长期停留在低频近似上, 则残差很难真正下降。

4.3 变分形式与非强制性

对 Dirichlet 问题, 将式(30)乘以测试函数 $v \in H_0^1(0, 1)$ 并分部积分, 得到弱形式: 求 $u \in H_0^1(0, 1)$ 使

$$a_k(u, v) = F(v), \quad \forall v \in H_0^1(0, 1), \quad (46)$$

其中

$$a_k(u, v) = \int_0^1 u'(x)v'(x) dx - k^2 \int_0^1 u(x)v(x) dx, \quad (47)$$

$$F(v) = \int_0^1 f(x)v(x) dx. \quad (48)$$

与 Poisson 方程不同,

$$a_k(v, v) = \|v'\|_{L^2}^2 - k^2 \|v\|_{L^2}^2 \quad (49)$$

不一定为正, 因此无法直接得到 Poisson 型强制性估计。不过它满足 Gårding 型结构:

$$a_k(v, v) + k^2 \|v\|_{L^2}^2 = \|v'\|_{L^2}^2. \quad (50)$$

这说明 Helmholtz 方程具有“椭圆主部 + 不定零阶项”的结构, 分析和数值稳定性都比 Poisson 方程更微妙。

5 谱偏差对 Helmholtz-PINN 的影响

5.1 强形式残差中的敏感抵消

对一维 Helmholtz 方程, PINN 残差为

$$r_\theta(x) = -u_\theta''(x) - k^2 u_\theta(x) - f(x). \quad (51)$$

当 $f = 0$ 且精确解为 $\sin(kx)$ 时, 精确解满足

$$-u'' = k^2 u. \quad (52)$$

这意味着方程要求二阶导数项与零阶项之间发生精确抵消。若网络近似在相位上稍有偏差, u_θ'' 与 $k^2 u_\theta$ 的抵消就会被破坏, 残差可能显著增大。

为了说明相位误差的影响, 设网络学到的函数近似为

$$u_\theta(x) = \sin(kx + \varphi). \quad (53)$$

若边界条件暂不考虑, 则它仍满足齐次 Helmholtz 方程, 因为频率仍为 k 。但是边界条

件会出现误差:

$$u_\theta(0) - u(0) = \sin \varphi, \quad u_\theta(1) - u(1) = \sin(k + \varphi) - \sin k. \quad (54)$$

若频率也有偏差, 即

$$u_\theta(x) = \sin((k + \delta)x), \quad (55)$$

则由命题1有

$$\mathcal{L}_k u_\theta = ((k + \delta)^2 - k^2) \sin((k + \delta)x) = (2k\delta + \delta^2) \sin((k + \delta)x). \quad (56)$$

这说明高波数情形下的频率误差会被 k 放大。

5.2 采样分辨率与波长

PINN 损失是在有限采样点上计算的。对于高频解, 如果内部采样点数量不足, 训练过程可能只在采样点处降低残差, 而无法保证采样点之间的行为正确。设波长为 $\lambda_{\text{wave}} = 2\pi/k$ 。若使用均匀采样点间距 h_s , 则每个波长上的采样点数大约为

$$N_\lambda \approx \frac{\lambda_{\text{wave}}}{h_s} = \frac{2\pi}{kh_s}. \quad (57)$$

为了观察振荡结构, 至少需要 N_λ 不太小。若 kh_s 较大, 则损失函数本身就无法充分分辨振荡。这个现象与传统网格方法中的“每个波长需要若干自由度”相似, 但在 PINN 中还叠加了优化偏差。

5.3 损失尺度随波数放大

强形式残差中有 $k^2 u_\theta$ 项。因此在不同 k 的问题之间直接比较残差 MSE 并不公平。若令

$$\tilde{r}_\theta(x) = \frac{-u_\theta''(x) - k^2 u_\theta(x) - f(x)}{1 + k^2}, \quad (58)$$

则归一化残差可以减弱 k 增大造成的尺度变化。在实际训练中, 若不做类似归一化, 优化器可能面对随 k 急剧变大的梯度尺度, 导致训练不稳定。

进一步设误差 $e = u_\theta - u$, 且边界条件被硬约束满足。由于 $\mathcal{L}_k u = f$, 有

$$r_\theta = \mathcal{L}_k u_\theta - f = \mathcal{L}_k e. \quad (59)$$

在频域中, 若

$$e(x) = \sum_{\xi} \hat{e}(\xi) e^{i\xi x}, \quad (60)$$

则

$$\hat{r}(\xi) = (\xi^2 - k^2)\hat{e}(\xi), \quad (61)$$

于是

$$\|r\|_{L^2}^2 \sim \sum_{\xi} |\xi^2 - k^2|^2 |\hat{e}(\xi)|^2. \quad (62)$$

式(62)清楚表明:Helmholtz 残差对频率结构十分敏感。PINN 不是简单拟合 u , 而是在频域上用权重 $|\xi^2 - k^2|^2$ 惩罚误差。

6 数值实验

本节给出两个实验。实验代码使用 Python 与 PyTorch 实现, 所有图表均由随文代码生成。为了保证实验可重复, 代码中固定随机种子为 20260608。实验目的不是追求最优 PINN 调参, 而是在统一训练预算下展示低频目标与高频目标之间的差异。

6.1 实验一: 函数拟合中的谱偏差

考虑区间 $[0, 1]$ 上的函数拟合问题:

$$f_k(x) = \sin(kx), \quad k = 5, 40. \quad (63)$$

普通 MLP 直接输入 x , Fourier-MLP 先使用

$$\gamma_k(x) = (\sin(\omega_j x), \cos(\omega_j x))_{j=1}^M, \quad \{\omega_j\} = \{1, 2, 4, 8, 16, 32, k\} \quad (64)$$

进行特征映射。训练损失为均方误差:

$$\mathcal{J}_{\text{fit}}(\theta) = \frac{1}{N} \sum_{i=1}^N |u_{\theta}(x_i) - \sin(kx_i)|^2. \quad (65)$$

测试误差使用相对 L^2 误差:

$$E_{L^2} = \frac{\|u_{\theta} - u\|_{L^2(0,1)}}{\|u\|_{L^2(0,1)}}. \quad (66)$$

图1展示了相对 L^2 误差随训练轮数的变化。普通 MLP 对 $k = 5$ 的低频目标拟合较快, 但对 $k = 40$ 的高频目标误差下降缓慢; Fourier-MLP 由于显式引入三角特征, 对高频函数拟合明显更好。这与谱偏差理论一致: 普通网络倾向于低频优先, 而 Fourier features 可以改善低维高频函数表示。






图 1: 函数拟合实验中的相对 L^2 误差。普通 MLP 对低频目标收敛较快, 对高频目标收敛明显变慢; Fourier-MLP 在高频目标上表现更好。

图2进一步展示了最终拟合曲线。对低频函数, 两种模型都能给出较好近似; 对高频函数, 普通 MLP 在相同训练预算下无法捕捉完整振荡, 而 Fourier-MLP 明显更接近精确函数。



(a) $\sin(5x)$



(b) $\sin(40x)$

图 2: 低频与高频函数的拟合结果。

6.2 实验二：一维 Helmholtz 方程的 PINN 求解

考虑齐次 Helmholtz 方程

$$-u''(x) - k^2 u(x) = 0, \quad x \in (0, 1), \quad (67)$$

边界条件为

$$u(0) = 0, \quad u(1) = \sin k, \quad (68)$$

精确解为 $u(x) = \sin(kx)$ 。为了严格满足边界条件, 本文采用硬约束试探函数

$$u_\theta(x) = x \sin k + x(1-x)N_\theta(x), \quad (69)$$

其中 N_θ 是神经网络。因为

$$u_\theta(0) = 0, \quad u_\theta(1) = \sin k, \quad (70)$$

边界条件自动满足, 训练时只需要最小化内部残差

$$\mathcal{J}_r(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} |-u_\theta''(x_i) - k^2 u_\theta(x_i)|^2. \quad (71)$$

表1给出了不同波数下普通 MLP-PINN 与 Fourier-PINN 的最终残差均方误差和相对 L^2 误差。随着 k 从 5 增大到 40, 普通 MLP-PINN 的误差明显恶化。Fourier 特征在较高波数下能降低部分残差, 但相对 L^2 误差仍接近 1, 说明仅改善输入特征不能自动解决强形式 Helmholtz-PINN 的训练问题。这里的实验结果应理解为对困难机制的展示, 而不是对各种 PINN 技巧调参后的最优性能比较。

表 1: 一维 Helmholtz-PINN 实验结果。Rel- L^2 表示相对 $L^2(0, 1)$ 误差。

波数 k	模型	最终残差 MSE	Rel- L^2 误差
5	MLP-PINN	1.4160	2.2000×10^{-2}
5	Fourier-PINN	1.0280×10^2	8.2887×10^{-1}
10	MLP-PINN	3.5622×10^2	1.0773
10	Fourier-PINN	5.8248×10^1	9.5397×10^{-1}
20	MLP-PINN	1.1746×10^4	1.0660
20	Fourier-PINN	4.2071×10^3	9.8514×10^{-1}
40	MLP-PINN	1.1326×10^5	1.0087
40	Fourier-PINN	8.1840×10^4	9.6754×10^{-1}

图3展示了部分波数下相对误差的训练曲线。可以看出, $k = 5$ 时普通 MLP-PINN 能较快达到较小误差, 而 $k = 20, 40$ 时误差长期停留在较高水平。这与前文的分析一致:

波数越大, 解的高频结构越明显, 谱偏差和残差尺度问题越突出。




图 3: Helmholtz-PINN 实验中的相对 L^2 误差训练曲线。高波数问题明显更难训练。

图4给出了 $k = 10$ 和 $k = 40$ 时的最终近似解。高波数下, 普通 MLP-PINN 难以捕捉正确振荡结构; Fourier-PINN 在部分波数上改善残差, 但仍可能出现相位误差或振幅误差。该结果说明, 对于 Helmholtz 方程, 单纯更换输入特征并不足以完全克服强形式 PINN 的困难, 还需要结合更合适的损失尺度、采样策略或变分结构。




 (a) $k = 10$

 (b) $k = 40$

图 4: 不同波数下 Helmholtz-PINN 的最终近似解。

6.3 实验结果的数学解释

表1中的现象可以用式(62)解释。若网络主要产生低频误差, 则对于 $|\xi| \ll k$, 残差权重大约为 k^4 :

$$|\xi^2 - k^2|^2 \approx k^4. \quad (72)$$

因此同样大小的低频误差在高波数问题中会造成更大的残差。另一方面, 若网络学到的频率接近但不等于 k , 即 $\xi = k + \delta$, 则

$$|\xi^2 - k^2|^2 = |2k\delta + \delta^2|^2 \approx 4k^2\delta^2. \quad (73)$$

这说明高波数问题不仅要求网络有高频表达能力, 还要求频率和相位足够准确。普通 MLP 的谱偏差会拖慢高频学习, 而强形式残差又放大频率误差, 二者叠加导致 Helmholtz-PINN 的困难。

7 改进方向讨论

7.1 引入与波数相关的 Fourier 特征

由于 Helmholtz 方程的振荡频率与 k 直接相关, 一个自然想法是在输入层显式加入 $\sin(kx)$ 、 $\cos(kx)$ 或更丰富的三角特征。例如可以取

$$\gamma_k(x) = (x, \sin(kx), \cos(kx), \sin(2kx), \cos(2kx)). \quad (74)$$

这与 Trefftz 方法的思想相近: 既然方程的局部解具有波动结构, 就应当让近似空间尽可能包含这类结构。Fourier features 正是神经网络语境下实现这一思想的一种方式。

不过, 实验也表明, Fourier features 并不是万能的。它们能改善函数表示, 但 PINN 还涉及微分残差、边界约束、优化过程和采样策略。如果残差项尺度过大, 或者优化器无法有效平衡不同频率成分, 训练仍可能失败。

7.2 弱形式与变分型 PINN

强形式 PINN 需要直接计算二阶导数, 这对 Helmholtz 方程尤其敏感。变分型 PINN (Variational PINN) 将弱形式写入损失函数 [9], 通过分部积分降低导数阶数, 从而可能提高训练稳定性。对于方程

$$-u'' - k^2 u = f, \quad (75)$$

弱形式对应

$$\int_0^1 u'_\theta(x) v'(x) dx - k^2 \int_0^1 u_\theta(x) v(x) dx = \int_0^1 f(x) v(x) dx. \quad (76)$$

若选择一组测试函数 $\{v_j\}_{j=1}^M$, 可以构造变分残差损失

$$\mathcal{J}_{\text{weak}}(\theta) = \sum_{j=1}^M \left| \int_0^1 u'_\theta v'_j dx - k^2 \int_0^1 u_\theta v_j dx - \int_0^1 f v_j dx \right|^2. \quad (77)$$

相比强形式残差, 弱形式更接近有限元方法, 也更容易引入稳定性分析。

7.3 与传统 Helmholtz 求解器和神经算子的关系

高频 Helmholtz 问题在传统数值计算中也不是简单问题。除有限元离散误差外, 线性代数层面还需要处理强不定性带来的迭代收敛困难; 例如 sweeping preconditioner、源传递、极化迹和优化 Schwarz 方法都可以理解为针对 Helmholtz 结构设计的专门预条件技术 [4]。这说明 Helmholtz 方程的困难并非 PINN 独有, 而是由波动算子的频率

结构决定。神经网络方法若要在此类问题上稳定工作,也需要吸收传统数值分析中的结构化思想,而不是仅依赖通用优化器。

另一方面,神经算子方法试图学习解算子

$$\mathcal{G}: f \mapsto u, \quad \mathcal{L}_k u = f, \quad (78)$$

而不是对每一个右端项重新训练一个网络。Fourier Neural Operator 在 Fourier 空间中参数化积分核,对具有平移不变或近似平移不变结构的问题尤其自然 [11]; 一般 neural operator 框架则把神经网络推广为函数空间之间的映射 [10]。不过,对于高波数 Helmholtz 方程,算子族随 k 的变化、边界条件以及共振附近的稳定性仍然是必须处理的核心问题。

7.4 采样策略与损失尺度

高波数问题需要足够密集的采样点。若每个波长上的采样点过少,损失函数无法分辨振荡结构。设希望每个波长至少有 m 个采样点,则由式(57)可得

$$h_s \lesssim \frac{2\pi}{mk}, \quad N_r \gtrsim \frac{mk}{2\pi}. \quad (79)$$

另一方面,Helmholtz 残差中 $k^2 u$ 项随波数增大而放大,因此损失函数可能需要适当归一化,例如使用式(58)。更进一步,可以使用自适应采样,在残差较大的区域增加采样点:

$$\rho(x) \propto |r_\theta(x)|^p + \varepsilon, \quad p > 0, \quad (80)$$

其中 ρ 是新的采样密度, ε 防止采样概率为零。

8 结论

本文讨论了神经网络的谱偏差及其在 Helmholtz 方程求解中的影响。谱偏差说明,标准神经网络训练通常低频优先,而高频成分收敛较慢。Helmholtz 方程在高波数下具有明显振荡结构,因而成为检验神经网络 PDE 求解能力的典型问题。

从 Fourier 分析看,Helmholtz 算子的符号为 $p_k(\xi) = \xi^2 - k^2$ 。这意味着残差对频率非常敏感:低频误差会被约 k^2 放大,而接近特征频率的微小频率偏差也会产生 $2k\delta$ 量级的残差。由此可见,Helmholtz-PINN 的困难不仅来自解的高频性,还来自强形式残差中 $-u_\theta''$ 与 $k^2 u_\theta$ 的敏感抵消。采样点不足时,PINN 还可能只在离散点上降低残差,而无法保证区间内部的振荡结构正确。

实验结果支持上述判断。普通 MLP 在函数拟合中明显偏向低频目标,对高频目标误差下降缓慢;在一维 Helmholtz-PINN 中,波数增大导致误差和残差显著恶化。Fourier features 能有效改善高频函数拟合,并在高波数 PINN 中降低部分残差,但不能单独完

全解决强形式 PINN 的训练困难。因此, 对于 Helmholtz 方程这类振荡型 PDE, 神经网络方法必须结合频率结构、采样分辨率、损失归一化和变分思想进行设计, 而不能简单依赖普通 MLP 的通用逼近能力。

总体而言, 谱偏差为理解神经网络求解振荡型 PDE 的局限提供了清晰解释。它提示我们: 科学机器学习并不是用神经网络替代所有传统数值方法, 而是要把 PDE 的数学结构、频率特征和机器学习的优化机制结合起来。对于 Helmholtz 方程, 未来更有前景的方向可能是 Fourier-feature PINN、Trefftz 型神经网络、弱形式 PINN 以及神经算子方法之间的结合; 其中 Fourier Neural Operator 和更一般的 neural operator 框架提供了从函数空间到函数空间学习 PDE 解算子的另一条路线 [11, 10].

参考文献

- [1] Ivo Babuška and Stefan A. Sauter. Is the pollution effect of the FEM avoidable for the helmholtz equation considering high wave numbers? *SIAM Review*, 39(3):451–484, 1997.
- [2] George Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989.
- [3] Oliver G. Ernst and Martin J. Gander. Why it is difficult to solve helmholtz problems with classical iterative methods. In Ivan G. Graham, Thomas Y. Hou, Omar Lakkis, and Robert Scheichl, editors, *Numerical Analysis of Multiscale Problems*, pages 325–363. Springer, 2012.
- [4] Martin J. Gander and Hui Zhang. A class of iterative solvers for the helmholtz equation: Factorizations, sweeping preconditioners, source transfer, single layer potentials, polarized traces, and optimized schwarz methods. *SIAM Review*, 61(1):3–76, 2019.
- [5] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.
- [6] Frank Ihlenburg. *Finite Element Analysis of Acoustic Scattering*. Springer, 1998.
- [7] Arthur Jacot, Franck Gabriel, and Clément Hongler. Neural tangent kernel: Convergence and generalization in neural networks. In *Advances in Neural Information Processing Systems*, volume 31, pages 8580–8589, 2018.
- [8] George Em Karniadakis, Ioannis G. Kevrekidis, Lu Lu, Paris Perdikaris, Sifan Wang, and Liu Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3(6):422–440, 2021.

- [9] Ehsan Kharazmi, Zhongqiang Zhang, and George Em Karniadakis. Variational physics-informed neural networks for solving partial differential equations, 2019.
- [10] Nikola Kovachki, Zongyi Li, Burigede Liu, Kamyar Azizzadenesheli, Kaushik Bhattacharya, Andrew Stuart, and Anima Anandkumar. Neural operator: Learning maps between function spaces with applications to pdes. *Journal of Machine Learning Research*, 24(89):1–97, 2023.
- [11] Zongyi Li, Nikola Kovachki, Kamyar Azizzadenesheli, Burigede Liu, Kaushik Bhattacharya, Andrew Stuart, and Anima Anandkumar. Fourier neural operator for parametric partial differential equations. In *International Conference on Learning Representations*, 2021.
- [12] Lu Lu, Xuhui Meng, Zhiping Mao, and George Em Karniadakis. DeepXDE: A deep learning library for solving differential equations. *SIAM Review*, 63(1):208–228, 2021.
- [13] Jens Markus Melenk and Stefan A. Sauter. Wavenumber explicit convergence analysis for galerkin discretizations of the helmholtz equation. *SIAM Journal on Numerical Analysis*, 49(3):1210–1243, 2011.
- [14] Nasim Rahaman, Aristide Baratin, Devansh Arpit, Felix Draxler, Min Lin, Fred Hamprecht, Yoshua Bengio, and Aaron Courville. On the spectral bias of neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 5301–5310, 2019.
- [15] Maziar Raissi, Paris Perdikaris, and George Em Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.
- [16] Justin Sirignano and Konstantinos Spiliopoulos. DGM: A deep learning algorithm for solving partial differential equations. *Journal of Computational Physics*, 375:1339–1364, 2018.
- [17] Vincent Sitzmann, Julien N. P. Martel, Alexander W. Bergman, David B. Lindell, and Gordon Wetzstein. Implicit neural representations with periodic activation functions. In *Advances in Neural Information Processing Systems*, volume 33, pages 7462–7473, 2020.
- [18] Matthew Tancik, Pratul P. Srinivasan, Ben Mildenhall, Sara Fridovich-Keil, Nithin Raghavan, Utkarsh Singhal, Ravi Ramamoorthi, Jonathan T. Barron, and Ren Ng. Fourier features let networks learn high frequency functions in low dimensional

- domains. In *Advances in Neural Information Processing Systems*, volume 33, pages 7537–7547, 2020.
- [19] Sifan Wang, Yujun Teng, and Paris Perdikaris. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5):A3055–A3081, 2021.
- [20] Zhi-Qin John Xu, Yaoyu Zhang, Tao Luo, Yanyang Xiao, and Zheng Ma. Frequency principle: Fourier analysis sheds light on deep neural networks. *Communications in Computational Physics*, 28(5):1746–1767, 2020.